

10. NoSQL

- Introducció
- Bases de dades SQL
- Bases de dades NoSQL
- Tipus de bases de dades NoSQL
- Bases de dades relacionals versus NoSQL
- Renunciem a...?
- Algunes tendències

Introducció

- Bases de dades operacionals => BD, DBD
 - Els sistemes OLTP guarden **dades estructurades** per facilitar i automatitzar les **operacions diàries** (transaccions)
 - El model relacional és l'estàndard de facto
- Bases de dades decisionals => DBD
 - Els sistemes de suport a decisions guarden dades **per analitzar-les**, per entendre el que està passant i per pronosticar el que passarà. Basades principalment en lectures.
 - Emmagatzematge de dades (Data Warehousing) i OLAP – estàndard de facto
- Bases de dades NoSQL => DBD (introducció), CBDE
 - Els sistemes NoSQL guarden **dades semiestructurades o no-estructurades** per a sistemes que requereixen quantitats molt, molt més massives de dades, i més eficiència en l'accés a les dades (web a gran escala, xarxes socials,...). Proporcionen flexibilitat en quan a canvis inesperats en la informació a emmagatzemar.
 - Diferents models: Clau-valor, Document, Graf, ...

DBD - obligatòria de l'especialitat ES

CBDE - complementària de l'especialitat ES

ABD - administració de sistemes operacionals - complementària de l'especialitat SI

Introducció - NoSQL: El nom

- “SQL” = SGBD relacionals tradicionals
- Entre els anys 1998-2009 van anar apareixent sistemes que finalment al 2009 es van etiquetar com a NoSQL. Catalitzador: Popularització massiva de les aplicacions web i l'accés generalitzat a Internet (PC o mòbil), aplicacions amb necessitats canviants de dades, grans volums de dades, i necessitat de gran velocitat d'accés.
- S'acaba la tendència “One size fits all”: No tots els problemes de gestió/anàlisi de dades es resolen millor usant **exclusivament** SGBD relacionals tradicionals
- “No SQL” $\neq$ No usar SQL
- “NoSQL” = “Not only SQL” = No usar **només** SGBD tradicionals

Introducció - Característiques dels SGBD

- Persistència
- Eficiència en l'accés
- Emmagatzematge de quantitats massives de dades
- Accés multi-usuari
- Seguretat
- Fiabilitat
- Conveniència

A partir dels anys 1998-2009 necessitat de sistemes amb:

- dades més massives,
- igual o més eficients sobretot en l'accés per consulta
- models de dades més flexibles

El sistemes NoSQL promovien inicialment que algunes d'aquestes característiques (consistència, fiabilitat) no s'implementessin a favor de l'eficiència d'accés

Bases de dades relacionals

- **Món real – Món conceptual – Món de les representacions**
 - Taules que representen classes d'objectes
 - Columnes que representen propietats dels objectes d'una classe
 - Claus foranes que representen associacions
 - PK, Check, Not null, Unique, per a restriccions sobre les dades
 - Triggers per implementar restriccions, redundàncies, ...
- **Facilitats per a canvis conceptuals:**
 - ALTER TABLE, ... per adaptar-se a canvis en el món real
- **Abstracció respecte al nivell físic:**
 - SELECT, INSERT, DELETE, UPDATE s'especifica el QUÈ i no el COM
 - Optimització de consultes
 - Canvis a nivell físic no afecten les aplicacions (p.ex: afegir índexos)

Bases de dades relacionals: Transaccions ACID


- **Atomicitat** - Tenint en compte totes les operacions que es fan sobre la base de dades en una transacció. L'atomicitat garanteix que es fan totes (en cas de commit) o no se'n fa cap.
- **Consistència** - Una transacció transforma la base de dades d'un estat consistent a un altre estat consistent. Hi ha consistència quan les dades de la base de dades satisfan les restriccions que han de complir.
- **Aïllament** (Isolation) – Tot i que diverses transaccions poden executar-se al mateix temps (concurrència), l'aïllament garanteix que cada transacció es comporta com si fos l'única que està operant en el sistema.
- **Definitivitat** - Un cop una transacció ha estat confirmada (commit), els seus efectes persisteixen a la base de dades, fins i tot en cas de fallada del sistema, o altres errors.

Bases de dades NoSQL

- **Grans volums de dades**
- **Replicació i distribució escalable**
 - Potencialment milers servidors (data centers)
 - Potencialment distribuïts per tot el món
- **Principalment per a consultes (alta eficiència), i poques actualitzacions**
- **Actualitzacions asíncrones**
- **Sense esquema predefinit**

Bases de dades NoSQL: Teorema CAP

- **Consistència**, disponibilitat (**A**availability), tolerància a **P**articions (fallada en les comunicacions entre servidors).
- Un sistema distribuït, quan es produeix una partició de xarxa inevitable, no es pot garantir alhora la disponibilitat (per a fer actualitzacions) i la consistència.
- **En NoSQL es prioritza la disponibilitat** quan hi ha una partició de xarxa, **abans que la consistència** (figura de la dreta).



Bases de dades NoSQL – Transaccions BASE

- Acrònim introduït per ser l'oposat a ACID
- **B**asically **A**valailable, **S**oft state, **E**ventually consistent.
- Característiques:
 - Consistència feble
 - Priorització de la disponibilitat
 - Respostes aproximades són acceptables
 - Optimista

Tipus de bases de dades NoSQL

■ Key-Value Stores

- Model de dades: Col·leccions de parelles <Key, Value>
- Responsabilitat de l'aplicació de parsejar el valor.
- Operacions de get/set/delete (guardar i recuperar valors sencers).
- Inicialment, valors sense cap tipus de format predefinit
- Actualment tendint a valors en formats com per exemple JSON

Key	Value
K1	AAA,BBB,CCC
K2	AAA,BBB
K3	AAA,DDD
K4	AAA,2,01/01/2015
K5	3,ZZZ,5623

Key	Value
...	
"BMW"	["1-Series", "3-Series", "5-Series", "5-Series GT", "7-Series", "X3", "X5", "X6", "Z4"]
"Buick"	["Enclave", "LaCrosse", "Lucerne", "Regal"]
"Cadillac"	["CTS", "DTS", "Escalade", "Escalade ESV", "Escalade EXT", "SRX", "STS"]
...	

[DB-Engines Ranking](#)

Tipus de bases de dades NoSQL

■ Wide-Column Stores

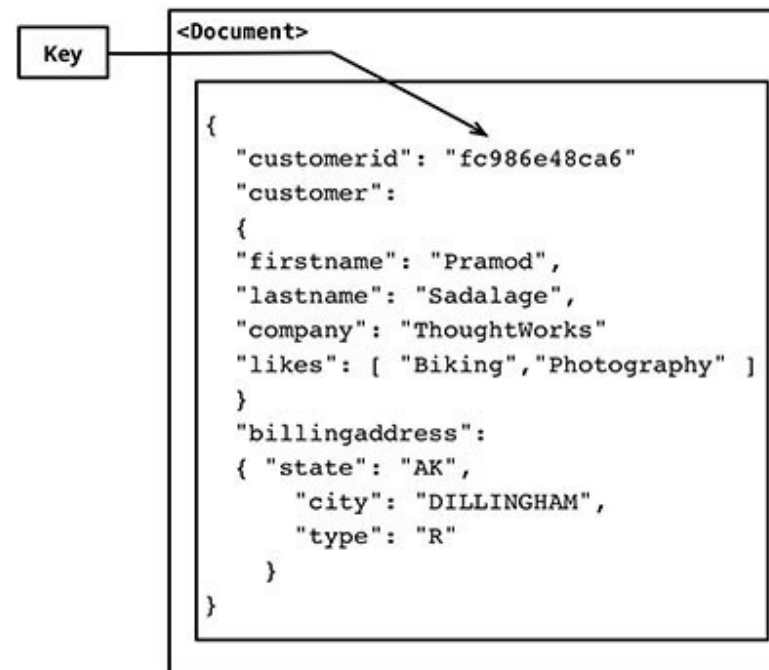
- Les dades s'emmagatzemen en taules com en el model relacional
- Esquema més flexible: el nom i format dels atributs pot variar d'una fila a una altra.
- Es pot veure com un Key-value store de dos nivells
- Cada fila és una família de columnes, on una família conté múltiples columnes relacionades.

Row ID	Columns...		
1	Name	Website	
	Preston	www.example.com	
2	Name	Website	
	Julia	www.example.com	
3	Name	Email	Website
	Alice	example@example.com	www.example.com

Tipus de bases de dades NOSQL

■ Document-stores


- Evolució dels Key-Value stores on el valor és semiestructurat
- Model de dades: Col·leccions de parelles <Key, Doc>, on Doc és un document XML o JSON.
- Consultes que poden referènciar el contingut del document (possible indexació del contingut)
- Molts han afegit llenguatges de més alt nivell (alguns SQL estès) i consistència ACID



Tipus de bases de dades NOSQL

■ Graph Databases

- Per aplicacions que usen grafs per modelar la seva informació semi-estructurada
- Model de dades: Graph structures (nodes i arestes)



Sumari Relacionals versus NoSQL


- **Bases de dades relacionals**
 - **Esquema predefinit**
 - **Llenguatge estàndard**
 - **Consistència forta** (ACID)
 - **Semàntica ben definida**
- **Bases de dades NoSQL**
 - Sense esquema predefinit (**schema-less**)
 - **Llenguatges propis** de cada producte
 - Prioritza **disponibilitat** i **escalabilitat** sobre consistència estricta
 - Orientades a **grans volums** i al **repartiment en molts nodes**
 - Optimitzades per **rendiment** sobretot pel que fa a consultes

Aleshores, renunciem a ...?

- **30 anys d'experiència amb SGBDR (RDBMS)**
- **És difícil superar un compilador**
 - El compilador tradueix SQL a operacions de baix nivell, i optimitza consultes.
 - En productes NoSQL inicialment requerien programació de baix nivell
 - Els llenguatges d'alt nivell són bons (independència de com s'emmagatzemen les dades, menys codi, ...)
- **Es pot garantir que més endavant no es necessitarà ACID?**
 - La consistència és bona per a les dades en els sistemes informàtics
 - Si es necessita consistència de dades, renunciar a l'ACID farà que s'hagi d'implementar feina que pot fer la base de dades en el codi de l'aplicació.

Algunes Tendències

- Els principals proveïdors de NoSQL han afegit:
 - Transaccions **ACID**
 - Llenguatge **SQL o adaptacions**
- **Sistemes multi-model.**
 - Sistemes que segueixen dos o més models de dades. Ex: PostgreSQL (model relacional, però també document store, incorporant atributs de tipus JSON).
- Sistemes relacionals que **emmagatzemen les dades per columnes**, en lloc de per files. Més eficiència per anàlisis de dades.
- **Sistemes de vectors** que emmagatzemen dades com a vectors numèrics (coneguts com a embeddings), que representen les característiques de la informació en un espai multidimensional. Habitualment generats per models d'IA, permetent fer cerques per similitud de manera molt eficient. Són ideals per a recuperar documents, imatges o fer recomanacions basades en el significat semàntic i no només en paraules clau exactes.



Stonebraker, Michael, and Andrew Pavlo. "What Goes Around Comes Around... And Around..." *ACM Sigmod Record* 53.2 (2024): 21-37.